パターン認識 – 課題 4

GENG Haopeng 611710008
Email: kevingenghaopeng@gmail.com

Department of Intelligent Systems, Nagoya University

2018 年 6 月 25 日

概要

今回の課題は、多層パーセプトロン、いわばニューラルネットワークによる学習である。課題 3 での解決しづらい問題、非線形可分離のパターンに応じる分離性能を評価し、iris データ集を使って学習結果を評価する実験である。そのほか、課題のソースコードが既に Github Repository に掲載されるため、解説が備え、参照あるいは実行することは可能である。

1　ニューラルネットワークによる学習 (基本編)

1.1　実験理論およびアルゴリズム

この課題は、最急降下法及び誤差逆伝搬法を利用し、ネットワークの各ニューラルの重みやバイオスを修正しつつ、パターンの非線形分離境界を見つける。学習のアルゴリズム [1] は以下のように表す：

1 外部から学習パターン、初期重み、バイオを入力する、必要なパラメータ (パターン次元数、クラスター数、ネットワーク層数) を獲得。
2 初期パラメータを用いてネットワークを築く。
3 前向き演算: パターン m において、
  – 3.1 パターン m の各次元を入力とする。
  – 3.2 隠れ層 i において、ニューラル j の入力を計算する。

$$g_{ij}(\boldsymbol{x}) = \boldsymbol{w}_{\boldsymbol{ij}}^{t}\boldsymbol{x}_{\boldsymbol{m}}$$

  – 3.3 活性化関数を通す。

$$h_{ij} = S(g_{ij})$$

  – 3.4 層 i の出力を層 $i+1$ の入力とする、step3.2 に戻る。
  – 3.5 全ての層を通過してから、パターン m 前向き演算終了。
4 後向き演算
  – 4.1 出力において、全ての学習パターンが収束しているかどうを判断。
  – 4.2 まだ収束していないパターンのある場合：
    * 4.2.1 出力層 o の各ニューラル j において、出力 h を用い、従来の重み w_k をもたらす誤差 ϵ を計算。

$$\epsilon_{o,j,k} = (h_{o,j} - bj)h_{o,j}(1 - h_{o,j})$$

    * 4.2.2 隠れ層 i の各ニューラル j において、出力 h を用い、従来の重み w_k をもたらす誤差 ϵ を計算。

$$\epsilon_{i,j,k} = (\sum_{i+1} \boldsymbol{\epsilon_{i+1,\Sigma_j}}\boldsymbol{w_{i+1,\Sigma_j,i}})h_{i,j,k}(1 - h_{i,j,k})$$

    * 4.2.3 各ニューラルに応じる誤差と従来の重みを用い、重みを修正する。

$$w'_{i,j,k} = w_{i,j,k} - \epsilon_{i,j,k}h_{i-1,j,k}$$

- 4.3 全てパターンが収束済みの場合、繰り返し演算終了。

5 学習済みの重みやバイオスを出力。

なお、今回の実験条件は表 1 のように表す。

表 1. 実験条件

学習パターン数	評価パターン数	パターン次元数	クラスター数	レイヤ数	レイヤごとのニューラル数	重み修正係数
6	1	2	2	2	3	0.1

1.2 プログラムに工夫した部分

後ろ向き演算のプロセスは以下のように表す。

ソースコード 1. Backward Calculation

```
    /* Backward */

     /* Get Output Layer's Epsilon */
     for(j = 0; j < Clu; j++){
       n_net[Layer - 1][j].e = op_layer_e(label[m][j], n_net[Layer - 1][j].h);
     }
     double e2bcorr[Clu], w2bcorr[Clu];
     /* Get Hidden Layers' Epsilon */
     for(i = Layer - 2; i >= 0; i--){
       for(j = 0; j < Clu; j++){
         e2bcorr[j] = n_net[i + 1][j].e;
       }
       for(j = 0; j < Clu; j++){
         for(k = 0; k < Clu; k++){
           w2bcorr[k] = n_net[i + 1][k].w[j];
         }
         n_net[i][j].e = hid_layer_e(w2bcorr, e2bcorr, n_net[i][j].h);
       }
     }
     /* After Eplison Generated, Update weights */
     /* Layer[1] ~ Layer[<output>] */
     for(i = Layer - 1; i > 0; i--){
       for(j = 0; j < Clu; j++){
         for(k = 0; k < Clu; k++){
           n_net[i][j].w[k] += - rho * n_net[i][j].e * n_net[i - 1][k].h;
         }
         b[i] += - rho * n_net[i][j].e;
       }
     }
     /* Layer[0] */
     for(j = 0; j < Clu; j++){
       for(k = 0; k < Dim; k++){
         n_net[0][j].w[k] += - rho * n_net[0][j].e * init_p[k];
       }
       b[0] += - rho * n_net[0][j].e;
     }
   }
   fprintf(tn_log_file,"\n");
 }
```

1.3 プログラム実行例

1.3.1 学習（パラメータ修正)

各パターンの各クラスターの出力において、訓練プロセスを可視化した。図 1 は例として、Epoch を 1000 に設定し、各パターンの訓練プロセスである。図 1 により、パターンに応じるクラスターの出力は最大であり、かつ誤差が小さめの方向に変動している。ゆえに現時点の重みは各学習パターンをうまく分離できることはわかった。

1.3.2 未知パターン識別

未知パターン (2, 2) を代入し、出力は以下のようである。ゆえに、Epoch = 1000 の時、正しい識別はできないことがわかった。Epoch の設定や収束条件の設定は考察の方に詳しく説明する。

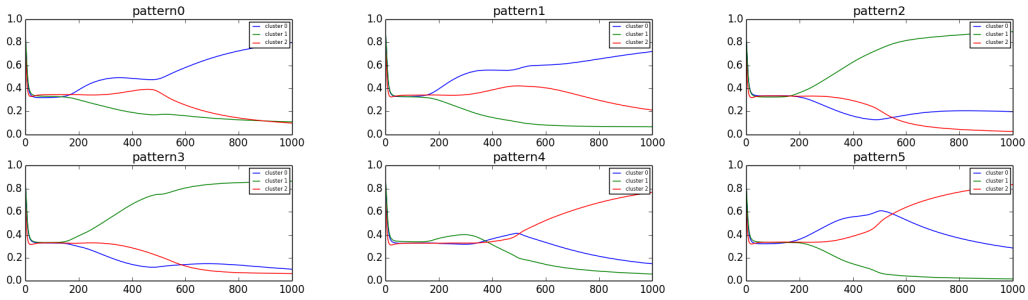

図 1. Training Process(Epoch=1000)

ソースコード 2. Recognition

```
2.000000 2.000000              ---> 各次元
0.942583,0.996466,0.997214,    ---> 出力
Recog result: CLuster[2]       ---> 識別結果
```

1.4 考察

1.4.1 収束条件による影響

より良い学習結果を得るため、収束までの繰り返し演算数 (Epoch) をいくつか設定し、分離結果を考察してみた。収束条件は：

1 弱条件：パターンに応じるクラスターの出力は他のクラスターの出力より大きい場合収束を認める。
2 強条件：パターンに応じるクラスターの出力は上限閾値を超え、かつ他のクラスターの出力は下限閾値以下になる場合収束を認める（ただし、今回は上、下限をそれぞれ 0.9、0.1 とする）。

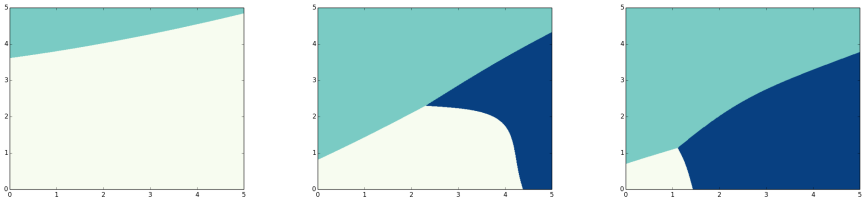

(i) epoch=100　(ii) epoch = 591(弱条件)　(iii) epoch = 1000

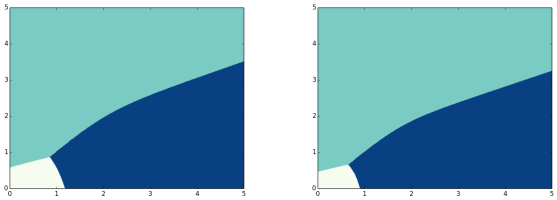

(iv) epoch = 1901(強条件)　(v) epoch = 10000

図 2. 収束条件による識別境界の変化

図 2 により、弱条件の場合、ニューラルネットワークの分離状況は理想的であると考えるが、条件が厳しくなると必ずしも識別能力が高くなる、いわば過学習現象 [2] が起こりやすい、ということが判明した。

2　ニューラルネットワークによる学習 (応用編)

2.1　実験目的

上記の実験に基づき、iris データセット (アヤメの萼片のながさ、幅、花びらのながさ、幅) を学習パターンとし、三種類のアヤメの分離状況を評価し、ニューラルネットワークの学習性能を評価する実験である。ただし、より良い分離性能を得るため、epoch 数及びレイヤ数を変数として扱う。

表 2.　iris 実験条件

学習パターン数	評価パターン数	パターン次元数	クラスター数	レイヤごとのニューラル数	重み修正係数
140	10	4	3	3	0.1

2.2　プログラム実行例

以下は例としてレイヤ数を 2 で、収束条件は「弱条件」に設定する時の実行結果である。

ソースコード 3.　Iris Recognition(2 Layers、Weak Convergence Condition)

```
Step2: Training
#         Choose Convergence Condition           #
# [ 0 ] --------  Weak Convergence Condition     #
# [ 1 ] --------  Strong Convergence Condition   #
# [ 2 ] --------  Test Mode(Define Epoch Number) #
0
#    Use Weak Convergence Condition   #
#          Generate Condition         #
#   Output[cluster] > Output[Others]  #

Epoch : 94
Step3: Recognition
Pattern[0]
0.998769,0.917666,0.386239,
True Cluster: [0]       Recog result: [0]
========
Pattern[1]
0.998789,0.916082,0.385725,
True Cluster: [0]       Recog result: [0]
========
Pattern[2]
0.293875,0.985167,0.984565,
True Cluster: [1]       Recog result: [1]
========
Pattern[3]
0.024372,0.910811,0.999029,
True Cluster: [1]       Recog result: [2]
========
Pattern[4]
0.534288,0.992362,0.959099,
True Cluster: [1]       Recog result: [1]
========
Pattern[5]
0.258434,0.983354,0.987012,
True Cluster: [1]       Recog result: [2]
========
Pattern[6]
0.021083,0.902353,0.999162,
True Cluster: [2]       Recog result: [2]
========
Pattern[7]
0.020714,0.901271,0.999177,
True Cluster: [2]       Recog result: [2]
========
Pattern[8]
0.031864,0.924838,0.998724,
True Cluster: [2]       Recog result: [2]
========
Pattern[9]
0.020646,0.901089,0.999179,
True Cluster: [2]       Recog result: [2]
========
Error Rate : 0.200000
```

結果により、この時の誤識別率は 20.0% であることが判明した。

2.3 考察

レイヤ数と収束条件を実験変量として、考察した結果は表 3 のように表す。

表 3. iris 実験結果

誤識別率 / 収束条件 / レイヤ数	epoch=100	epoch=500	epoch=1000	epoch=5000	弱条件	強条件
2	10%	10%	10%	10%	20%(epoch=94)	60%(epoch=25709)
3	10%	50%	60%	60%	20%(epoch=115)	60%(epoch=10622)
4	80%	70%	70%	60%	40%(epoch=205)	60%(epoch=12430)

よって、今回の実験において、レイヤ数とも関わらず、epoch が弱条件に近い方の識別率が高い。なお、予想と違って、ネットワークが複雑になればなるほど、識別結果が悪くなる。その原因の一つは、パターンの複雑度（次元数、クラスター数、データ量）がそれほど多くないため、あえて学習能力の高い識別マシンを使うと、識別マシンの容量（capacity）は現在の学習パターンにとって不適切であることと考える。[2]

そして、実験中他の発見において、初期重みの設定は収束速度と収束結果にかなり影響を与えている。なお、学習パターンの入力順序は実験結果にも影響があることも気づいた。今回においては、ランダムに入力するよりも、一連同じ種類パターンを順序で入力した方 (バッチ処理と相似) の実験結果が良いということがわかった。

3 ニューラルネットワークで遊ぶ

A Neural Network Playground で考察した結果は以下のようである。

- 1 活性化関数によって、分離性能も異なる。提供された非線形可分離のデータにおいて、*Tanh* の性能は高い。
- 2 各層のニューラル数は必ずしも多いほうが良い。
- 3 一部分の学習プロセスにおいて、コスト関数の値は一時的に安定し、さらに不安定になる場合もある。上記の実験の学習プロセスには、似たような現象も起こり得るが。原因はいまいちわからない、勾配の最急降下法に関する問題であると考える。

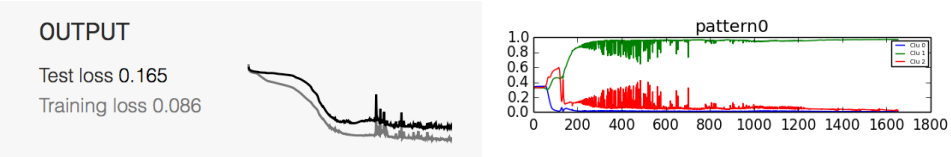

(i) Tensorflow　　(ii) iris データ集

図 3. 学習中の不安定現象

参考文献

[1] 石井健一郎, 上田修功, 村瀬洋, 等. わかりやすいパターン認識 [M]. Ohmsha, 1998.

[2] Ian Goodfellow,Yoshua Bengio, Aaron Courville. Deep Learning. MIT Press, 2016.